

Entrepôts de données 2025-2026 TP

Dans le cadre de ce sujet de TP, il s'agira d'étudier certaines données utilisées dans le cube MDX Foodmart. Ces données vous sont fournies au format CSV. Ce TP est divisé en plusieurs parties.

Partie A : étude des données sources

Cette partie concerne l'étude des fichiers sources fournis.

1. Pour chaque fichier, indiquer, selon vous, quel est le type/la nature des données qu'il contient ?
2. Pour mieux comprendre encore le contenu de ces fichiers, quel est, selon vous, le sens des attributs suivants :
 - Attribut `mi` du fichier `tb_customer_data.csv`
 - Attributs `SKU` et `SRP` du fichier `tb_product_data.csv`
3. En utilisant la correspondance entre les noms des attributs, proposer un schéma dans le format souhaité (schéma relationnel, entité/association, diagramme UML) permettant de modéliser les liens entre les différentes données. Les noms des entités sont issus des noms de fichiers (`tb_"entité"_data.csv`).

Partie B : analyse des données

Dans cette partie, vous utiliserez le langage de votre choix, disponible en salle de TP. Pour chaque interrogation, vous fournirez le programme réalisé ainsi que le résultat obtenu.

1. Quel est le classement des produits suivant leur nombre de ventes (Unit Sales) ? Donner un résultat partiel.
2. Quels sont les 10 produits les plus vendus (Unit Sales) ?
3. Quel est l'identifiant, la marque et le nom du produit le plus vendu (Unit Sales) ?
4. Proposer un programme permettant de retrouver le résultat de la requête MDX 2 (transparent 35 du cours), sans que l'affichage soit forcément identique.
5. Proposer un programme permettant de retrouver le résultat de la requête MDX 4 (transparent 39 du cours), sans que l'affichage soit forcément identique.
6. Proposer un programme permettant de retrouver le résultat de la requête MDX 7 (transparent 45 du cours), sans que l'affichage soit forcément identique.

Partie C : entrepôt de données

Dans cette partie, on définit les dimensions suivantes en se basant sur les attributs des fichiers sources fournis et, sur le cube MDX foodmart présenté en cours :

- Dimension Time
 - Année > Trimestre > Mois > Jour
 - `time_by_day.the_year` > `time_by_day.quarter` > `time_by_day.month_of_year` > `time_by_day.day_of_month`
- Dimension Store
 - Pays > Région > Ville > Boutique
 - `store.store_country` > `store.store_state` > `store.store_city` > `store.store_name`
- Dimension Product
 - Famille > Sous-Famille > Catégorie > Sous-Catégorie > Marque > Modèle
 - `product_class.product_family` > `product_class.product_department` > `product_class.product_category` > `product_class.product_subcategory` > `product.brand_name` > `product.product_name`

A ces dimensions, on ajoute les faits `unit_sales` et `profit` :

- Le fait `unit_sales` est issu de `sales_fact_1997.unit_sales`
- Le fait `profit` est la différence entre `sales_fact_1997.store_sales` et `sales_fact_1997.store_cost`

Pour chaque script ou requête SQL ci-dessous, donner leur résultat.

1. Proposer un script SQL permettant de créer l'entrepôt de données `edd_sales1997` qui vient d'être défini.
2. Proposer un programme de type ETL permettant de remplir l'entrepôt de données `edd_sales1997` à partir des fichiers sources, fournis au début du TP, en se limitant à l'année 1997.
3. Proposer une requête SQL qui affiche les 10 produits les plus vendus (`unit_sales`).
4. Proposer une requête SQL permettant de visualiser l'évolution du nombre cumulé de ventes (`unit_sales`) mois après mois (tout produit confondu).
5. Proposer une requête SQL qui affiche le bénéfice (`profit`) des 5 produits les plus vendus (`unit_sales`).
6. Proposer une requête SQL qui affiche, pour chaque famille de produits, les 3 produits qui ont généré le plus grand bénéfice (`profit`).
7. Proposer une requête SQL qui donne les nombres de boutiques contribuant à moins de 10000 \$, entre 10000 et 20000 \$ exclus, entre 20000 et 30000 \$ exclus, entre 30000 et 40000 \$ exclus, et à au moins 40000 \$ au bénéfice (`profit`). Proposer une requête complémentaire SQL aidant à vérifier votre résultat.
8. Proposer une (unique) requête SQL permettant d'afficher le bénéfice (`profit`) total ainsi que les bénéfices par famille de produits, par trimestre, par région (`store_state`) ; par trimestre et par région ; par région.